

Algoritmos Genéticos Aplicados ao Planejamento da Distribuição de Energia Elétrica em Curitiba e Região Metropolitana

Arileide Cristina Alves,* Maria Teresinha Arns Steiner,
Nelson Haj Mussi e Giovani Zanelatto

Resumo: Para o contínuo crescimento dos municípios torna-se necessário a expansão otimizada das redes de distribuição de energia elétrica. A localização e o balanceamento otimizados de SE's são questões de grande importância para um planejamento adequado. Neste capítulo é abordado o problema de localização de instalações (*facilities location*), sendo que a região de estudo é o município de Curitiba e adjacências. Foram aplicados os Algoritmos Genéticos, sendo que a melhor solução obtida foi refinada através do algoritmo Teitz e Bart. O algoritmo de Gillett e Johnson é usado para a definição da região de atendimento de cada SE. A metodologia proposta serve como auxílio ao engenheiro tomador de decisões.

Palavras-chave: Planejamento de distribuição, Localização de instalações, Algoritmos genéticos.

Abstract: *The continuous development of the cities requires to an optimized expansion of energy distribution networks. The location and optimized load distribution of substations are subjects of great importance to an adequate planning. This chapter focuses the facilities location problem, and the area of study is the city of Curitiba and surroundings. Genetic algorithms were used and the best solution found was later refined through the Teitz and Bart algorithm. The Gillett and Johnson algorithm is used to define the service area for each substation. The proposed methodology serves as a tool to the decision maker engineer.*

Keywords: *Distribution planning, Facilities location, Genetic algorithms.*

* Autor para contato: aalves@up.com.br

1. Introdução

O crescimento de um país afeta diretamente o crescimento e o aumento do mercado consumidor de energia elétrica. Por outro lado, dificuldades econômicas podem provocar restrições de verbas para os investimentos. Tais fatores geram a necessidade de se elaborar estudos mais complexos, para o suprimento de energia elétrica a uma determinada área, que podem envolver uma massa de dados com muitas informações, exigindo análise detalhada de um número maior de alternativas para os mais diversos problemas. Além disto, existe a necessidade de se ter respostas rápidas para o consumidor que tem se tornado cada vez mais exigente, tanto com relação ao tempo em que fica privado do fornecimento de energia elétrica, quanto em relação ao número de vezes que isto ocorre.

Todos estes fatores, por si só, já apontam para a necessidade de ajustes das concessionárias de energia elétrica com relação aos serviços prestados. Estes ajustes são comumente tratados através do planejamento de distribuição de energia elétrica em redes, que é o processo de estudos e análises que visa garantir a eficiência de uma rede elétrica. Um planejamento de distribuição satisfatório inclui tamanho, locação, rotas, interconexões e previsão do momento (“quando”) e locais adequados (“onde”) para futuras linhas de transmissão, subestações, alimentadores e equipamentos relacionados à distribuição de energia elétrica.

No que diz respeito à localização e dimensionamento de subestações, torna-se evidente a necessidade de adotar estudos de técnicas que permitam a otimização do processo, que pode ser obtida com o uso de modelos matemáticos e algoritmos, assim como proposto neste trabalho.

Tal otimização faz uso dos mapas de carga que são representações gráficas da distribuição de carga em uma localidade ou região, convenientemente subdividida em áreas elementares (quadrículas), que são as menores unidades de área a serem consideradas na distribuição geográfica de carga. Sua definição depende do tipo de estudo a ser realizado. Por exemplo, para o planejamento de subestações em Curitiba, Região Metropolitana (RMC) e adjacências, são utilizadas quadrículas de área de 1 km². Os dados utilizados neste estudo foram fornecidos pela concessionária de energia elétrica, através de uma planilha eletrônica, em ambiente Microsoft Excel, contendo as suas coordenadas no sistema Universal Transversa de Mercator (UTM), as demandas de cargas em cada uma delas, bem como a localização e a capacidade de atendimento das subestações existentes.

Problemas de localização de instalações (ou medianas) aparecem frequentemente na prática em uma variedade de aplicações como, por exemplo, a localização do centro de comutação numa rede telefônica, armazéns de suprimentos numa rede de distribuição e a localização de centros de triagens de cartas, dentre outras.

São muitos os trabalhos apresentados na literatura que tratam de problemas reais, cuja solução recai ou faz uso dos problemas de localização de instalações. Dentre estes trabalhos pode-se citar o de [Corrêa \(2000\)](#) onde são aplicados os algoritmos metaheurísticos algoritmos genéticos e busca tabu, comparativamente para o problema das p -medianas capacitado. Neste problema o objetivo principal era determinar cerca de 20 instalações, dentre cerca de 40 possibilidades, que melhor acomodassem, em termos de distância, os cerca de 50 mil candidatos ao vestibular da Universidade Federal do Paraná (UFPR).

Em [Detofeno & Steiner \(2010\)](#) é apresentada uma metodologia para a obtenção de rotas otimizadas para a coleta de resíduos urbanos. Para tanto, foi utilizada primeiramente a heurística de Teitz e Bart para a obtenção de p -medianas. A partir da definição destas, foram definidos grupos (*clusters*) de pontos de demanda através da designação destes às medianas, fazendo uso do algoritmo de Gillett e Jonhson. Finalmente, a partir da definição dos grupos de pontos, foi utilizado o algoritmo do Carteiro Chinês, obtendo-se o roteamento (sequenciamento dos pontos de demanda a serem atendidos) em cada um dos grupos de atendimento.

Em [Scarpin et al. \(2008\)](#) é apresentada uma proposta para a otimização no serviço de saúde no estado do Paraná com relação ao fluxo de pacientes dentro do estado e a regionalização (divisão) do estado, obtendo novas configurações hierárquicas para o mesmo. Quanto à regionalização, a proposta consiste em dividir o estado em regiões menores, formadas por várias cidades, vinculadas a uma cidade-sede. Para isto, foi feito uso do algoritmo *branch-and-price*, que utiliza o algoritmo de geração de colunas em cada nó de uma árvore *branch-and-bound*. Este algoritmo se mostrou eficiente melhorando a divisão hierárquica do estado, levando em consideração o “número de habitantes” e o “número de procedimentos médicos” de cada município do estado. Os resultados obtidos têm atendido as expectativas da Secretaria de Saúde do estado do Paraná (SESA-PR).

Em [Smiderle et al. \(2004\)](#) é proposta uma metodologia para a obtenção de uma solução otimizada dos leituristas dos medidores das contas de água, da Companhia de Saneamento do Paraná (SANEPAR) no município de Pato Branco. Inicialmente foi aplicado um algoritmo genético para se determinar as p -medianas ($p = 12 =$ número de leituristas), cuja resposta pode ser melhorada com a heurística clássica de Teitz e Bart. A partir daí, foram definidos os grupos (*clusters*) de pontos a serem atendidos por cada funcionário através do algoritmo de designação adaptado de Gillett e Johnson. A partir da definição dos *clusters*, foi realizado o roteamento para ter-se a sequência de pontos a serem visitados, utilizando o modelo matemático do problema do Carteiro Chinês.

O objetivo deste trabalho é apresentar técnicas que visam otimizar a localização e o balanceamento de subestações de distribuição de energia elétrica na cidade de Curitiba, RMC e adjacências, para o horizonte de

um ano, usando técnicas da área da Pesquisa Operacional. O problema apresentado se enquadra como um problema de localização de facilidades (*facilities location*). Para a localização “ótima” de uma nova subestação foram utilizados os Algoritmos Genéticos, cuja melhor solução obtida ao final do procedimento foi melhorada através do algoritmo de Teitz e Bart. O Algoritmo de Gillett e Johnson é usado para definir a região de atendimento, isto é, fazer um “balanceamento” de cada subestação pertencente à área de estudos, levando-se em conta as coordenadas e as capacidades de atendimento reais de cada uma. O algoritmo de Gillett Johnson cumpre este objetivo por agrupar quadrículas (com suas respectivas demandas de carga), à subestação que as atenda tornando mínimo o percurso das cargas, ou seja, minimizando o momento elétrico (produto da carga pela distância por ela percorrida).

A metodologia proposta se mostrou bastante adequada ao problema, lembrando que um atendimento satisfatório em relação à demanda de energia elétrica para uma determinada região é, na verdade, um problema de transporte de cargas através de uma rede.

A seção 2 apresenta brevemente o contexto do problema de localização de instalações, assim como os algoritmos matemáticos da área de Pesquisa Operacional utilizados à solução do problema real aqui abordado: os algoritmos genéticos (AG's), o algoritmo de Teitz e Bart (TB) e o algoritmo de Gillett e Johnson (GJ). Na seção 3 é apresentada a metodologia para a solução do problema em si, que consta do levantamento dos dados e a forma de aplicação dos algoritmos mencionados. Na seção 4 são apresentados os resultados de algumas das numerosas simulações realizadas e, finalmente, na seção 5, as conclusões do trabalho.

2. O Problema de Localização de Instalações

A localização “ótima” de uma possível nova subestação deve levar em conta fatores tais como:

- custo e facilidade de conexão com os alimentadores de transmissão e distribuição já existentes;
- limites de tensão e corrente, que podem afetar o número e os custos dos alimentadores necessários para a alimentação de uma determinada área;
- possibilidade de transferência de carga de uma subestação para outras em condições de emergência, ou quando do aumento na demanda de carga;
- custo e disponibilidade de terrenos próximos ao local desejado;
- restrições devido a eventuais leis de zoneamento.

Tais fatores implicam em investimentos na rede elétrica. Para que a nova subestação assuma parte da demanda da rede, é necessário planejamento adequado dos investimentos envolvidos nesta empresa concomitantemente à construção da mesma. Este fato evidencia a necessidade de subentender-se também a restauração de uma rede com planejamento, levando-se em conta que a localização de uma subestação é fator importante no que diz respeito à manutenção de serviços adequados e continuidade do fornecimento de energia aos consumidores (Gruppelli Jr. et al., 2002).

No caso destes problemas de localização serem de pequeno porte, a solução pode ser encontrada de forma exata, através de um modelo de programação inteira ou enumeração exaustiva (ou busca em árvore). Este último método foi usado por Revelle & Swain (1970) para encontrar as 3-medianas de um grafo com 10 vértices, dando início ao estudo deste tipo de problema. Existem, também, os métodos aproximados (ou heurísticos), usados por vários pesquisadores como, por exemplo, Teitz & Bart (1968), os quais se aplicam a problemas de médio e grande porte. Para estes casos pode-se utilizar, também, técnicas metaheurísticas, dentre as quais destacam-se os algoritmos genéticos (AG's) (Corrêa et al., 2004).

Considerando-se todos os vértices de um grafo dado como potenciais medianas, o problema de p -medianas pode ser definido como segue: seja $G(V, A)$ um grafo não direcionado onde V é o conjunto de vértices e A o conjunto de arestas. Deve-se encontrar um conjunto de vértices $V_p \subset V$ (conjunto de medianas) com cardinalidade p , tal que a soma das distâncias de cada um dos vértices restantes em $\{V - V_p\}$, considerando-se as demandas de cada vértice até seu vértice mais próximo em V_p seja a mínima possível.

Uma formulação do problema de p -medianas como um modelo matemático de programação inteira binária, desenvolvida por Revelle & Swain (1970), é apresentada a seguir. Este modelo permite que cada vértice de um grafo seja considerado, ao mesmo tempo, como demanda e instalação (potencial mediana), embora em muitos casos demandas e instalações pertençam a conjuntos disjuntos.

$$\text{Min} \sum_{i=1}^n \sum_{j=1}^n a_i d_{ij} x_{ij} \quad (1)$$

sujeito a:

$$\sum_{j=1}^n x_{ij} = 1, \quad i = 1, 2, \dots, n \quad (2)$$

$$x_{i,j} \leq y_i, \quad i, j = 1, 2, \dots, n \quad (3)$$

$$\sum_{j=1}^n y_j = p \quad (4)$$

$$x_{ij}, y_j \in \{0, 1\}, \quad i, j = 1, 2, \dots, n \quad (5)$$

onde:

n = número total de vértices do grafo;

a_i = demanda do vértice i ;

d_{ij} = distância do vértice i ao vértice j ;

p = número de instalações utilizadas como medianas;

$$x_{ij} = \begin{cases} 1, & \text{se o vértice } j \text{ for designado para a instalação } i; \\ 0, & \text{caso contrário} \end{cases}$$

$$y_j = \begin{cases} 1, & \text{se o vértice } j \text{ for uma instalação utilizada como mediana;} \\ 0, & \text{caso contrário} \end{cases}$$

A função objetivo na Equação 1 minimiza a soma das distâncias ponderadas dos vértices de demanda até o conjunto de medianas. O conjunto de restrições em (2) garante que todos os vértices de demanda serão designados para exatamente uma única mediana. O conjunto de restrições em (3) proíbe que um vértice de demanda seja designado para uma instalação que não esteja selecionada como mediana. O número total de vértices medianas (instalações selecionadas) é definido pela restrição em (4) como sendo igual a p . Por fim, a restrição em (5) garante que os valores das variáveis de decisão x_{ij} e y_j sejam binários (assumindo os valores “0” ou “1”).

A utilização deste modelo matemático fica restrita a problemas de pequeno porte pelo fato das variáveis serem binárias. Além disto, há a falta de flexibilidade do mesmo para se considerar no problema, por exemplo, as 30 subestações já existentes, conforme será visto mais adiante. Por este motivo, fez-se uso aqui da metaheurística AG seguida da heurística TB para a definição da localização das medianas (subestações) e, em seguida, da heurística de GJ para o balanceamento (distribuição das cargas) às medianas. Todos estes três algoritmos estão descritos a seguir.

2.1 Breve descrição dos algoritmos genéticos (AG's)

Os AG's são sistemas inspirados na natureza, simulando os processos naturais, utilizados para a resolução de problemas reais. São métodos ge-

neralizados de busca e otimização que simulam os processos naturais de evolução, aplicando a idéia Darwiniana de seleção. Os AG's diferem dos métodos exatos de busca e otimização, principalmente em três aspectos: trabalham a partir de uma população de soluções e não com uma única solução, utilizam informações de custo ou recompensa e não derivadas ou outro conhecimento auxiliar, utilizam regras de transição probabilísticas e não determinísticas.

Para serem utilizados, os AG's exigem que inicialmente seja gerada uma população formada por um conjunto aleatório de indivíduos que podem ser vistos como possíveis soluções do problema. A população inicial, assim como as demais que são geradas durante o processo evolutivo são avaliadas: para cada indivíduo é atribuído um valor (*fitness*), ou índice, refletindo a sua habilidade de adaptação a determinado ambiente. A probabilidade dos indivíduos mais adaptados serem mantidos é maior do que a dos indivíduos menos adaptados (Darwinismo).

Os indivíduos mantidos pela seleção podem sofrer modificações em suas características fundamentais através de mutações e cruzamentos (*crossover* ou recombinação genética), gerando descendentes para a próxima geração. Este processo é repetido até que algum critério de parada (número de iterações, convergência das soluções/genes, dentre outros) seja atendido.

Alguns critérios básicos devem ser levados em conta quando da aplicação de AG's à solução de um problema. Tais critérios abrangem aspectos como codificação, função de avaliação (*fitness*), operadores genéticos (*crossover*, mutação), taxas probabilísticas de realização dos operadores genéticos, critérios de seleção, reprodução, critério de parada e convergência prematura, dentre outros. A Seção 3 deste trabalho mostra os critérios utilizados à simulação numérica do algoritmo para o problema abordado. Os demais critérios são amplamente discutidos em [Alves \(2002\)](#).

O operador genético *crossover* toma dois indivíduos previamente selecionados através de algum critério e realiza o seu “cruzamento”, ou seja, a troca de seus materiais genéticos. Este cruzamento pode ocorrer de diversas formas, sendo que três delas são apresentadas nas figuras 1, 2 e 3, a seguir. Vale salientar que o operador *crossover* busca solução a partir do conhecimento dos indivíduos já existentes (*exploitation*). Novos indivíduos podem ser gerados pelo cruzamento de indivíduos diferentes.

Por outro lado, o operador de mutação busca uma solução em regiões factíveis ainda não avaliadas (*exploration*). A figura 4 ilustra um dos diversos tipos de operador genético de mutação e apresenta apenas uma das formas de se realizar a mutação. A mutação é responsável pela geração de novos pontos no espaço de soluções.

Podem ser destacadas algumas variações no operador de mutação ([Sampaio, 1999](#)). Por exemplo, a mutação por inversão é caracterizada pela retirada de uma parte do cromossomo e a sua recolocação no indivíduo na ordem inversa em que foi retirada. Já na mutação por translocação,

Figura 1. *Crossover* de uma partição.Figura 2. *Crossover* de duas partições.Figura 3. *Crossover* de três partições.

Gene sorteado aleatoriamente para mutação

Figura 4. *Crossover* de três partições.

parte do cromossomo é retirada e colocada em outra posição, guardando a ordem com a qual foi retirada. A hipermutação, mostrada por [Corrêa et al. \(2004\)](#), é uma operação onde se realiza a mutação em todos os genes possíveis, avaliando-se em qual deles é melhor que se estabeleça a inserção do material genético.

Para problemas de otimização, o ideal seria que o algoritmo finalizasse assim que a solução ótima (ponto ótimo) fosse descoberta. No caso de funções multimodais, um ponto ótimo pode ser o suficiente, mas pode haver situações onde todos ou o maior número possível sejam desejados. O uso de um algoritmo evolutivo não permite afirmar se um dado ponto ótimo corresponde a um ótimo global ou local.

Como consequência, normalmente utiliza-se como critério de parada o número máximo de gerações (iterações) ou tempo limite de processamento. Outro critério plausível, segundo [Corrêa et al. \(2004\)](#), é finalizar a execução do algoritmo usando a idéia de estagnação, ou seja, quando não se observa alterações dos desvios padrão dos valores de adaptação entre duas iterações consecutivas. Assim, se não houver a melhoria da população depois de várias gerações consecutivas, o algoritmo encerra o processamento.

2.2 Descrição do algoritmo de Teitz e Bart (TB) para o problema das p -medianas

Uma das heurísticas mais conhecidas para solução do problema das p -medianas é a desenvolvida por [Teitz & Bart \(1968\)](#), conhecida como al-

goritmo das p -medianas de Teitz e Bart. Esta heurística é baseada na substituição de vértices e seu objetivo é, a partir de uma solução inicial, melhorar o valor da função objetivo a cada iteração.

Segundo Corrêa et al. (2004), esta heurística produz boas soluções, principalmente quando aplicada várias vezes ao mesmo problema com diferentes soluções iniciais. Considerando-se todos os vértices de um grafo dado como potenciais medianas, o algoritmo de Teitz e Bart para o problema das p -medianas pode ser explicado como segue.

Seja V o conjunto de todos os vértices do grafo e S o conjunto das medianas (S está contido em V), testa-se se qualquer vértice ν_i , com $\nu_i \in \{V - S\}$ pode substituir um vértice ν_j , com ν_j pertencente a S e produzir um novo conjunto S' , onde $S' = S \cup \{\nu_i\} - \{\nu_j\}$ para o qual temos o número de transmissão¹ $NT(S') < NT(S)$.

Se isto for possível, é feita a substituição de ν_j por ν_i , e S' será uma nova aproximação para o conjunto ν_p . O processo continua até que se obtenha um conjunto $S_{\text{médio}}$, onde nenhuma substituição de vértice de $S_{\text{médio}}$ por outro em $\{V - S_{\text{médio}}\}$ produz um número de transmissão menor.

O algoritmo de Teitz e Bart é apresentado através dos passos a seguir.

1. selecione aleatoriamente um conjunto S , com a cardinalidade igual a p (ou seja, $|S| = p$) para formar uma aproximação inicial para as p -medianas;
2. rotule todos os vértices pertencentes a $\{V - S\}$ como “não analisados”;
3. enquanto existirem vértices “não analisados” em $\{V - S\}$, faça:
 - (a) selecione um vértice ν_i pertencente a $\{V - S\}$, “não analisado”, e calcule a redução A do número de transmissão, para todo ν_j pertencente a S : $A_{ij} = NT(S) - NT(S \cup \{\nu_i\} - \{\nu_j\})$
 - (b) faça $A_{ij_0} = \text{Max}[A_{ij}]$;
 - (c) se $A_{ij_0} > 0$ faça $S = S \cup \{\nu_i\} - \{\nu_{j_0}\}$ e rotule ν_{j_0} como “analisado”;
 - (d) se $A_{ij_0} \leq 0$, rotule ν_i como “analisado”.
4. caso durante a execução do passo 3 ocorram modificações no conjunto S , volte ao passo 2. Caso contrário, pare, e apresente o conjunto S como uma aproximação para a solução do problema de p -medianas.

¹ Número de Transmissão: é a soma das menores distâncias existentes entre o vértice ν_j e todos os outros vértices do grafo.

2.3 O algoritmo de Gillett e Johnson

O algoritmo proposto por Gillett e Johnson – GJ (Bodin et al., 1983) faz a designação dos pontos de demanda (cargas) às medianas (neste caso, as subestações – SE's), cujas localizações já foram definidas através dos procedimentos descritos nas seções 2.1 e 2.2. Inicialmente, todas as medianas encontram-se sem designação.

Para cada carga (demanda) i , seja $Q_1(i)$ a distância de i até o posto de atendimento (subestação) mais próximo a i , e $Q_2(i)$, a distância de i até o segundo posto de atendimento (subestação) mais próximo a i . Para cada demanda i , a razão: $r(i) = \frac{|Q_1(i)|}{|Q_2(i)|}$ é calculada e todas as demandas são colocadas numa “lista de designação” em ordem crescente pelos valores de $r(i)$. A designação começa pelos primeiros elementos da lista (demandas com menor razão $r(i)$), e é feita obedecendo-se a capacidade dos postos de atendimento.

Durante a designação, sempre que uma demanda é designada para um posto de atendimento com a capacidade esgotada (evidentemente sem sucesso), a razão $r(i)$ é recalculada para todas as demandas que ainda não tenham sido designadas, considerando-se apenas os postos de atendimento cujas capacidades ainda não estejam esgotadas. Estas demandas são novamente colocadas na “lista de designação” em ordem crescente pelos valores de $r(i)$ e a designação continua até que todas as demandas sejam designadas para algum posto de atendimento.

Através do cálculo da razão $r(i)$ procura-se conhecer a “urgência” de se fazer a designação de uma demanda em relação às demais, pois quanto menor for o valor de $r(i)$, maior é a urgência já que o segundo posto de atendimento mais próximo ficaria em posição bem pior para a demanda a ser atendida em relação ao primeiro. A seguir é apresentado o algoritmo GJ, passo a passo.

1. Para todo ponto de demanda i não designado, faça:
 - (a) encontre $Q_1(i)$ e $Q_2(i)$, respectivamente o primeiro e o segundo postos de atendimento mais próximos do ponto do ponto i cujas capacidades não estejam esgotadas.
 - (b) calcule a razão: $r(i) = \frac{|Q_1(i)|}{|Q_2(i)|}$.
 - (c) coloque o ponto de demanda i na “lista de designação” pela ordem crescente dos valores de $r(i)$.
 - (d) iniciando pelo topo da “lista de designação” designe o ponto de demanda i para o posto de atendimento mais próximo.
2. Enquanto existirem pontos de demanda sem designação, faça:
 - (a) designe o ponto de demanda atual da “lista de designação” para o posto de atendimento mais próximo.

- (b) Diminua a demanda do ponto de demanda i da capacidade do posto de atendimento para a qual a demanda i foi designada.
- (c) Se a capacidade do posto de atendimento que recebeu a demanda atual ficar esgotada, ou não puder atender a próxima demanda, então volte ao Passo 1 e recalcule a “lista de designação”, desconsiderando os postos de atendimento com capacidade esgotadas. Caso contrário, continue.

Na Seção 3, a seguir, é apresentada a metodologia para solução do problema aqui abordado.

3. Metodologia para a solução do problema

A metodologia é composta das seguintes etapas: levantamento dos dados; aplicação do AG para determinar a localização (quase) ótima das novas subestações; aplicação do algoritmo de TB para o refinamento da solução fornecida pelo AG e, finalmente a aplicação do algoritmo de GJ para a definição dos grupos de quadriculas que deverão ser atendidos por cada uma das subestações.

3.1 Levantamento dos dados

Os dados levantados para o desenvolvimento do trabalho aqui apresentado foram concedidos pelo setor de distribuição de energia da concessionária, através de planilha Microsoft Excel®. A região estudada, ou seja, o município de Curitiba, RMC e adjacências, por ocasião do estudo, estava constituída por 2013 quadriculas, cada uma das quais com cerca de 1 km².


Para cada quadricula obteve-se: o seu número, a sua localização e a sua demanda (carga necessária para atender todas as cargas contidas na quadricula, em KVA). Para cada subestação obteve-se: a sua localização e o valor de sua capacidade em KVA.

3.2 Aplicação do algoritmo genético – GENE

Para solução do problema da localização de subestações, a codificação escolhida para este problema é tal que cada cromossomo ficou definido como um vetor de $(30+n)$ genes, cujos alelos são o número das quadriculas (como consequência, sabe-se a posição de cada SE), sendo que o número “30” é o número de subestações já existentes na região estudada e, portanto, fixas e n representa a quantidade de possíveis novas subestações desejadas (n , portanto, é um dado a ser fornecido pelo engenheiro usuário do programa).

Nestes cromossomos são aplicados os operadores genéticos, utilizando apenas os n alelos que representam as novas possíveis subestações. Depois disto, a melhor solução é vinculada ao cromossomo inicial que deve conter os alelos das 30 subestações fixas e aplica-se, então, o algoritmo de TB para

o refinamento da solução. A figura 5 exemplifica os cromossomos utilizados no programa.



Legenda:

- Genes correspondentes às subestações j existentes, ou seja, fixas (30);
- Genes correspondentes às subestações que serão criadas (n).

Figura 5. Representação de um cromossomo para o problema das SE's.

Um segundo parâmetro a ser considerado é o tamanho da população. Segundo [Reeves \(2000\)](#), populações pequenas podem provocar um sério risco de não “cobrir” o espaço de busca, enquanto que populações grandes podem exigir um esforço computacional excessivo para a resolução do problema. Além disto, pode-se citar [Cunha & Pinto \(2001\)](#) que afirmam que não existem parâmetros ótimos para os operadores genéticos. Os problemas cuja solução é encontrada através de algoritmos genéticos utilizam, de uma forma geral, de 50 a 200 cromossomos para população inicial ([Tanomaru, 1995](#)). Neste trabalho, o número de cromossomos usados nas simulações obedece a este critério. No programa computacional utilizado (MATLAB), a função GENE (que executa o algoritmo genético) permite que o usuário decida quantos cromossomos terá a população inicial.

Depois de se gerar aleatoriamente a população inicial, ordenou-se os cromossomos pelo seu *fitness* que, neste caso, é o momento elétrico (medido em KVA/km), usado para avaliar o investimento em redes primárias de distribuição, como mostrado em [Savulescu \(1981\)](#). A partir disto, deve-se selecionar indivíduos (cromossomos) para recombinação.

A seleção de cromossomos pode ser aleatória ou ordenada. Porém, os melhores resultados foram obtidos utilizando-se a seleção ordenada, na qual se adota o mesmo critério proposto por [Mayerle \(1994\)](#), mostrada na Equação 6 a seguir, que segundo [Corrêa et al. \(2004\)](#) privilegia a escolha de indivíduos com melhor *fitness*:

$$Select(R) = \left\{ r_j \in R / j = p - \left\lfloor \frac{-1\sqrt{1 + 4 \cdot rnd \cdot (p^2 + p)}}{2} \right\rfloor \right\} \quad (6)$$

onde R é uma lista $R = (R_1, R_2, R_3, \dots, R_p)$, com p cromossomos colocados em ordem crescente pelo valor de *fitness*; $rnd \in [0, 1)$ é um número aleatório uniformemente distribuído e o símbolo $\lfloor b \rfloor$ significa o maior inteiro menor que b . A função $Select(R)$ retorna um número aleatório igual à posição na lista R do cromossomo que será selecionado. Apesar de ser aleatório, o

número retornado tem maior tendência de selecionar os primeiros elementos da lista R (que são os melhores indivíduos da lista).

Realizada a seleção de dois cromossomos através da função $Select(R)$, inicia-se a utilização dos operadores genéticos. O primeiro deles é o *crossover*, que para esse trabalho, segue os passos:

1. Selecionados os dois cromossomos (“pais”), estes são ordenados gene a gene, de modo a permitir que as subestações próximas entre si fiquem em genes próximos. Sem esta ordenação, é possível que os cruzamentos apresentem muitos “filhos” inviáveis, uma vez que existem limitações físicas de atendimento a uma demanda de carga entre uma subestação e outra. Subestações muito distantes entre si não teriam viabilidade elétrica para “trocar” cargas.
2. Selecionar o ponto de corte (ou ponto de cruzamento), ou seja, determinar a partir de qual gene o material genético entre os cromossomos será “trocado”. No programa utilizado, as opções disponíveis para o usuário são “1”, onde o ponto de corte será escolhido através de uma função, ou “0”, o ponto de corte será escolhido aleatoriamente.
3. Selecionar quantos genes a partir do ponto de corte sofrerão influência dos operadores genéticos. Este número é um inteiro pertencente ao intervalo $[31, 30 + n]$, onde n representa, como já mencionado, o número de novas possíveis subestações. O operador genético *crossover* é executado enquanto houver melhora no *fitness* da população.

3.3 Aplicação do algoritmo Teitz e Bart (TB)

O programa desenvolvido em MATLAB contém o algoritmo de TB apresentado na seção 2.2 e, para executá-lo, é preciso indicar a melhor solução obtida através do AG, ou seja, a localização das novas n ($= 5$) subestações, indicadas pelas quadrículas.

O objetivo do algoritmo TB é refinar a solução fornecida pelo AG (localização das subestações), ou seja, tentar melhorar tais localizações de forma a obter o momento elétrico total mínimo.

3.4 Aplicação do algoritmo de Gillett e Johnson (GJ)

A função GJ do programa utiliza o algoritmo apresentado na seção 2.3. Este algoritmo objetiva distribuir (designar) as demandas de cargas de cada quadrícula para as subestações que estejam mais próximas, levando-se em conta os valores das demandas e as capacidades de atendimento das subestações.

Basicamente, a função GJ procura designar demandas de carga a subestações que as possam atender e, ao mesmo tempo, que exijam o menor momento elétrico possível. Para cumprir tal propósito, um número $r(i)$ que

indica a urgência que existe em se designar certa demanda a uma determinada subestação é calculado, para garantir o mínimo momento elétrico, conforme já mostrado na seção 2.3.

4. Resultados

A forma como o programa principal foi elaborado permite a interação com os engenheiros responsáveis pelo planejamento da distribuição da concessionária (Alves, 2002). São permitidos estudos de casos diversos, sob circunstâncias diversas. Dentre as variações possíveis, podem ser destacados: o fator de multiplicação das cargas (FMC); o tipo de mutação, pois a escolha do gene que sofrerá mutação pode ser ou não aleatória; a mutação pode ser do tipo usual (um gene é trocado) ou do tipo multimutação (dois ou mais genes podem ser trocados); o tipo de cruzamento, visto que os cruzamentos podem ocorrer apenas nos n genes que estão situados à direita dos 30 primeiros genes, que representam subestações fixas já existentes. Pode-se ainda escolher quantas partições terá o cruzamento.

Alguns resultados são apresentados na tabela 1 que inclui dados como: número do estudo de caso (indicado por EC); número de possíveis novas subestações (NSE); número de cromossomos na população inicial (POP); número de iterações realizadas para obtenção da solução (NIT); cruzamentos efetivos (CE); o número de vezes em que mutações foram efetivas (ME); fator de multiplicação de cargas (FMC); tempo de processamento em segundos (TPS); carga total atendida em KVA (CTA) e momento elétrico total em KVA/km (MET).

As três primeiras linhas de cada caso referem-se a cruzamentos de uma partição e mutações usuais. A quarta linha de cada um dos casos refere-se a cruzamentos com duas (ou mais) partições e multimutações; a quinta linha de cada caso refere-se ao cruzamento de uma partição e mutação usual com aplicação do fator de multiplicação de cargas.

No caso de duas novas SE's, por exemplo, nota-se que a melhor solução em termos de momento elétrico mínimo se dá com população inicial de 70 cromossomos. Note-se, porém, que esta não é a melhor solução em tempo computacional. Isto indica que a figura humana do engenheiro responsável pelo planejamento da distribuição continua essencial no processo da decisão, uma vez que as prioridades devem ser por ele estabelecidas.

Os gráficos em MATLAB que mostram localizações ótimas de novas subestações para a região de estudos (levando-se em conta as subestações já existentes) bem como relatórios comparativos e os mapas com a localização atual das SE's já existentes na região de estudos, além de detalhes relativos a dados e implementação, podem ser encontrados em Alves (2002).

Tabela 1. Resultados obtidos em simulações.

EC	NSE	POP	NIT	CE	ME	FMC	TPS	CTA	MET
1	2	50	660	114	8	1, 0	522, 78	1074441, 4434	2410752, 9135
	2	70	880	162	5	1, 0	738, 47	1074441, 4434	2404392, 7553
	2	100	1210	226	4	1, 0	1114, 16	1074441, 4434	2410706, 9461
	2	50	660	99	14	1, 0	520, 42	1074441, 4434	2426580, 7237
	2	50	660	124	12	1, 2	535, 80	1289329, 7321	3102563, 5211
2	3	50	660	181	3	1, 0	545, 02	1074441, 4434	2365808, 196
	3	70	880	249	3	1, 0	803, 17	1074441, 4434	2359764, 1721
	3	100	1210	397	7	1, 0	1129, 26	1074441, 4434	2353716, 7041
	3	50	660	156	5	1, 0	545, 68	1074441, 4434	2367253, 8042
	3	50	660	178	5	1, 2	564, 91	1289329, 7321	3028174, 275
3	4	50	660	227	1	1, 0	584, 90	1074441, 4434	2331332, 5941
	4	70	880	260	5	1, 0	790, 76	1074441, 4434	2322294, 322
	4	100	1210	481	4	1, 0	1162, 45	1074441, 4434	2309606, 8806
	4	50	660	212	2	1, 0	575, 45	1074441, 4434	2310477, 186
	4	50	660	218	3	1, 2	575, 56	1289329, 7321	2972560, 9579
4	5	50	660	202	4	1, 0	588, 36	1074441, 4434	2281608, 1026
	5	70	880	292	7	1, 0	830, 63	1074441, 4434	2275504, 3639
	5	100	1210	502	6	1, 0	1208, 59	1074441, 4434	2259551, 3123
	5	50	660	195	3	1, 0	596, 27	1074441, 4434	2280611, 0121
	5	50	660	222	11	1, 2	609, 02	1289329, 7321	2876943, 6252

5. Conclusões

O estudo do problema de localização de instalações, aplicado ao problema da localização das SE's tem como objetivo a automação da localização de novas possíveis subestações. Com este trabalho, pretende-se desenvolver uma ferramenta útil aos engenheiros da área de distribuição responsáveis pela localização otimizada, de forma local ou até mesmo global das mesmas.

É certo que muitas alternativas na geração de energia são pesquisadas como, por exemplo: geração eólica, solar, pelas oscilações das ondas dos mares, etc. Mas, sem dúvida, além de avanço e pesquisa quanto à geração de energia, precisa-se ter em mente a preocupação com a sua distribuição. Para tanto, é vital um planejamento adequado, que se inicia sempre pela decisão do melhor local de construção de uma SE. Nesse trabalho, propõe-se a utilização de Algoritmos Genéticos para a concessionária.

A metodologia proposta serve como auxílio para a solução do problema, mas, a figura do tomador de decisões, neste caso, o engenheiro responsável pelo planejamento de subestações é imprescindível. Quando se procura unicamente a minimização do momento elétrico, muitas soluções satisfatórias podem ser encontradas. Entretanto, dentre estas, pode haver aquela cujo resultado não seja “o melhor” matematicamente mas, quando considerado o contexto do empreendimento (a construção de uma nova subestação), é possível que fatores como disponibilidade do terreno ideal, incluindo seu custo e outros, a torne mais atrativa do que a solução “melhor” em termos matemáticos. As opções e decisões pertencem ao cabedal de experiência do setor de planejamento.

Outros estudos podem ser realizados nesta direção e algumas sugestões para trabalhos são: explorar o assunto para outros anos do horizonte de previsão do setor estudos de mercado através da Programação Dinâmica; verificar, junto às concessionárias locais sobre quais melhorias poderiam ser realizadas no programa computacional para a sua utilização efetiva; incluir cálculos que envolvam investimentos na rede, a fim de detectar se a ampliação da capacidade de uma subestação é ou não mais apropriada do que a construção de uma nova subestação, a curto, médio ou longo prazo. Com relação ao problema real, um estudo sobre técnicas aplicáveis ao problema de cargas que deixam de ser atendidas pelas subestações pode ser alvo de pesquisa; com relação ao problema das p -medianas, é possível analisar outras heurísticas para solucioná-lo. Segundo [Glover et al. \(2000\)](#), o *Scatter Search* e *Path Relinking* têm sido mais eficientes do que os algoritmos genéticos e a busca tabu em alguns problemas.

Referências

- Alves, A., *Algoritmos genéticos aplicados ao Planejamento da Distribuição de Energia Elétrica em Curitiba e Região Metropolitana – A Localização das Subestações*. Dissertação de mestrado, Métodos Numéricos em Engenharia, Universidade Federal do Paraná, Curitiba, PR, 2002.
- Bodin, L.; Golden, B.; Assad, A. & Ball, M., Routing and scheduling of vehicles and crews – the state of the art. *Computers and Operations Research*, 10(2):63–212, 1983.
- Corrêa, E.S., *Algoritmos Genéticos e Busca Tabu Aplicados ao Problema das p -medianas*. Dissertação de mestrado, Métodos Numéricos em Engenharia, Universidade Federal do Paraná, Curitiba, PR, 2000.
- Corrêa, E.S.; Steiner, M.T.A.; Freitas, A.A. & Carnieri, C., A genetic algorithm for solving a capacitated p -median problem. *Numerical Algorithms*, 35(2-4):373–388, 2004.
- Cunha, A.S. & Pinto, R.L.U.S., Uma técnica para ajuste dos parâmetros de um algoritmo genético. In: *Anais do XXXIII Simpósio Brasileiro de Pesquisa Operacional*. Campos do Jordão, SP, p. 1105–1116, 2001.
- Detofeno, T.C. & Steiner, M.T.A., Optimizing routes for the collection of urban solid waste: a case study for the city of Joinville, state of Santa Catarina. *IJIE - Revista Iberoamericana de Engenharia Industrial*, 2(1):124–136, 2010.
- Glover, F.; Laguna, M. & Martí, R.. *Control and Cybernetics*, 29(3):653–684, 2000.
- Gruppelli Jr., F.A.; Yuan, J.Y.; Carnieri, C.; Volpi, N.M.P.; Steiner, M.T.A.; Wilhelm, V.E.; Mussi, N.H.; Antonio, C.; Miqueles, E.; Andretta Filho, E.L.; Kalinowski, A.; Alves, A.C.; Gulín, C.; Zambenedetti, V.C. & Klimkowski, M., Algoritmos para recomposição de sis-

- temas de distribuição. In: *Anais do XV SENDI - Seminário Nacional de Distribuição de Energia Elétrica*. Salvador, BA, 2002.
- Mayerle, S.F., Um algoritmo genético para a solução do problema do caixeiro viajante. In: *Anais do 14º ENEGEP - Encontro Nacional de Engenharia de Produção*. João Pessoa, PB, 1994.
- Reeves, C.R., *Modern Heuristic Techniques for Combinatorial Problems*. New York, USA: McGraw-Hill, 2000. 320 p.
- Revelle, C.S. & Swain, R.W., Central facilities location. *Geographical Analysis*, 2(1):30–42, 1970.
- Sampaio, M.E.C.S., *Aplicação de Metaheurísticas ao problema de localização de escolas de ensino fundamental*. Dissertação de mestrado, Métodos Numéricos em Engenharia, Universidade Federal do Paraná, Curitiba, PR, 1999.
- Savulescu, S.C., *Grafos, dígrafos e redes elétricas - aplicações na Pesquisa Operacional*. São Paulo, SP: Editora IBEC, 1981.
- Scarpin, C.T.; Steiner, M.T.A.; Dias, G.J.C. & Steiner Neto, P.J., Otimização no serviço de saúde do estado do Paraná: fluxo de pacientes e novas configurações hierárquicas. *Revista Gestão & Produção*, 15(2):275–290, 2008.
- Smiderle, A.; Steiner, M.T.A. & Wilhelm, V., Técnicas da pesquisa operacional aplicadas a um problema de cobertura de arcos. *TEMA – Tendências em Matemática Aplicada e Computacional*, 5(2):347–356, 2004.
- Tanomaru, J., Motivação, fundamentos e aplicações de algoritmos genéticos. In: *Anais do II Congresso Brasileiro de Redes Neurais*. Curitiba, PR, p. 373–403, 1995.
- Teitz, M.B. & Bart, P., Heuristic methods for estimating the generalized vertex median of weighted graph. *Operations Research*, 16(5):955–961, 1968.

Notas Biográficas

Arleide Cristina Alves é Mestre em Métodos Numéricos em Engenharia e Doutora em Engenharia Mecânica, ambos pela Universidade Federal do Paraná (UFPR). Atualmente é professora na Universidade Positivo (UP) e na Universidade Tecnológica Federal do Paraná (UTFPR) nas engenharias Elétrica, Mecânica e da Computação.

Maria Teresinha Arns Steiner é Mestre e Doutora em Engenharia de Produção pela Universidade Federal de Santa Catarina (UFSC) e tem Pós-Doutorado em Pesquisa Operacional pelo Instituto Tecnológico da Aeronáutica (ITA). Atualmente é professora sênior dos Programas de Pós-Graduação em Métodos Numéricos em Engenharia (Mestrado e Doutorado) e de Engenharia de Produção (Mestrado), ambos da Universidade Federal do Paraná (UFPR).

Nelson Haj Mussi é Mestre em Métodos Numéricos em Engenharia pela Universidade Federal do Paraná (UFPR). É funcionário aposentado da COPEL (Companhia Paranaense de Energia Elétrica).

Giovani Zanelatto é Mestre e Doutor em Física pela Universidade Federal de São Carlos e tem Pós-Doutorado em Física pela University of California, Santa Barbara. Atualmente é professor na Universidade Positivo (UP).